

Machine Learning e Visão Computacional [T1]

Mini-Projeto Avaliativo - Módulo 2 - Semana 07

SUMÁRIO

1 CONTEXTUALIZAÇÃO	1
2 DESAFIO	1
3 RESULTADOS ESPERADOS	1
4 REQUISITOS DAS TAREFAS	2
4.1 GRAVAÇÃO DE VÍDEO	2
5 CRITÉRIOS DE AVALIAÇÃO	2

1 CONTEXTUALIZAÇÃO

A Indústria 4.0 transformou a maneira como as fábricas operam, integrando tecnologias inteligentes para otimizar a produção e garantir o controle de qualidade. No mercado de trabalho atual, a automação da inspeção visual exige profissionais capazes de transitar entre duas abordagens: a Visão Clássica e a Inteligência Artificial.

Muitas vezes, antes de treinarmos uma rede neural complexa, precisamos usar ferramentas de processamento clássico (como a biblioteca OpenCV) para realizar uma análise exploratória, limpando ruídos, destacando bordas e compreendendo as características físicas do defeito que a máquina precisará procurar. Somente após essa compreensão, aplicamos Redes Neurais Convolucionais (CNNs) para automatizar a classificação em larga escala, substituindo inspeções manuais demoradas e sujeitas a erros humanos.

Neste projeto, utilizaremos o dataset público *Casting Product Image Data for Quality Inspection* (disponível no Drive: <https://drive.google.com/file/d/1NZOjCHDRrpn7PmbFKVqegUP5arfdXHKK/view?usp=sharing>), que contém imagens reais de peças de fundição metálica com e sem defeitos estruturais.

2 DESAFIO

Você foi contratado como Analista de Inteligência Artificial Júnior por uma indústria metalúrgica. Seu desafio técnico é desenvolver um pipeline (script) em Python que una processamento clássico e aprendizado profundo.

O objetivo do seu código é duplo:

1. **Análise Exploratória (OpenCV):** Extrair uma amostra de imagens do dataset e aplicar um pipeline clássico de tratamento (escala de cinza, blur, limiarização, detecção de bordas e morfologia) para provar visualmente que é possível destacar a ranhura ou trinca da peça.
2. **Classificação Automatizada (TensorFlow/Keras):** Ingerir o lote completo de imagens, aplicar *Data Augmentation* dinâmico para simular variações de esteira e treinar uma Rede Neural Convolutiva (CNN) básica capaz de classificar a peça como "OK" ou "Defeituosa". Ao final, gerar o gráfico de *Loss* e *Acurácia* do modelo.

3 RESULTADOS ESPERADOS (ENTREGA)

O arquivo [readme.md](#) com a solução do mini-projeto e o vídeo deverão ser inseridos no Google Drive em modo leitor para qualquer pessoa com o link, e o planejamento e organização ficará a critério de cada estudante. Os links deverão ser submetidos na tarefa **Módulo 2 - Mini-Projeto Avaliativo**, presente no AVA, até o dia **//2026 às h.**

4 REQUISITOS DAS TAREFAS

Para garantir a organização e o sucesso do projeto, divida seu desenvolvimento nas seguintes Sprints industriais:

- **Sprint 1: Configuração e Versionamento:** Inicializar um repositório Git, configurar o ambiente de notebooks e fazer o download do dataset.
- **Sprint 2: Análise Exploratória Clássica (OpenCV):** Selecionar imagens de amostra e aplicar técnicas de conversão para escala de cinza (*Grayscale*) e suavização de ruídos industriais (ex: *Gaussian Blur* ou *Median Blur*).
- **Sprint 3: Destaque de Características:** Ainda na amostra, aplicar limiarização (*Thresholding*) e algoritmos de detecção de bordas (*Canny* ou *Sobel*), além de operações morfológicas (*Erosão/Dilatação*) para isolar visualmente os defeitos da peça.
- **Sprint 4: Ingestão de Dados e Augmentation (Keras):** Utilizar [image_dataset_from_directory](#) para carregar o dataset completo dividindo em Treino e Validação. Implementar *Data Augmentation* (giros, zoom, brilho) para imunizar a IA.
- **Sprint 5: A Arquitetura CNN e Treinamento:** Construir um modelo Sequencial com camadas [Conv2D](#) e [MaxPooling2D](#), finalizando com o achatamento ([Flatten](#)) e a camada de classificação binária ([Dense](#)). Executar o treinamento com o otimizador *Adam*.
- **Sprint 6: Auditoria e Gravação:** Gerar o gráfico analítico do treinamento (Curvas de *Loss* e *Val_Loss*), redigir o [readme.md](#) finalizando a branch no GitHub e gravar o vídeo técnico de apresentação.

4.1 GRAVAÇÃO DE VÍDEO

Além do desenvolvimento do código, você deverá gravar um vídeo, com tempo máximo de 5 minutos, abordando os seguintes questionamentos:

1. Qual o objetivo do sistema e demonstração de funcionamento no notebook?
2. O que as técnicas clássicas de OpenCV (Canny, Blur) revelaram sobre os defeitos da peça na sua análise exploratória?
3. Como você estruturou a sua CNN e o *Data Augmentation* para aprender esses padrões em larga escala?
4. Analisando o seu gráfico de *Loss* gerado no final, ocorreu *Overfitting* ou o modelo aprendeu de forma saudável?

Você poderá gravar na vertical ou na horizontal. O arquivo de vídeo (ou link) deve estar acessível via Google Drive.

5 CRITÉRIOS DE AVALIAÇÃO

A tabela abaixo apresenta os critérios que serão avaliados durante a correção do projeto, variando de 0 a 10 pontos. Projetos que apresentarem plágio de soluções encontradas na internet ou de outros colegas receberão nota 0 (zero). O uso de IA generativa para consulta é permitido, desde que o código final seja compreendido e defendido pelo aluno no vídeo.

Apresentação do Projeto				
Nº	Critério de Avaliação	0	1,50	3,00
1	Gravação do Vídeo (Até 3,00 pts): Responde aos 5 questionamentos propostos, demonstra os gráficos e o OpenCV rodando, respeitando o tempo de 5 min.	Não entregou ou não atendeu aos requisitos básicos.	Atendeu parcialmente a todos os requisitos solicitados.	Atendeu plenamente a todos os requisitos solicitados.

Desenvolvimento do Projeto

Nº	Critério de Avaliação	0	0,25	0,50
2	Versionamento e Documentação (Até 1,00 pt): Uso correto de Git (branches, commits lógicos) e readme.md com instruções de execução e link do vídeo.	Não utilizou Git.	Uso parcial ou commits sem padrão claro.	Versionamento completo e bem estruturado.
3	OpenCV: Filtros Básicos (Até 1,00 pt): Aplicação correta de conversão de cores (Grayscale) e filtros de suavização (Blur) na amostra de análise.	Sem README.	README incompleto.	README detalhado e formatado.
4	OpenCV: Bordas e Morfologia (Até 1,00 pt): Sucesso ao destacar o defeito da peça utilizando Limiarização, Canny/Sobel e Morfologia (Dilatação/Erosão).	Desorganizado.	Organização parcial.	Estrutura clara e eficiente.
5	Ingestão e Augmentation (Até 1,00 pt): Leitura otimizada das pastas em lote via Keras e	Lê apenas imagens fixas.	Lê pasta com falhas.	Automação de leitura perfeita.

	aplicação de <i>Data Augmentation</i> geométrico/luminoso.			
6	Arquitetura CNN (Até 1,00 pt): Configuração estrutural válida com blocos intercalados de Extração de Características (<i>Conv2D</i> e <i>MaxPooling2D</i>).	Não aplicou.	Aplicou incorretamente.	Aplicou corretamente.
7	Compilação e Decisão (Até 1,00 pt): Correta transição matricial (<i>Flatten</i>) e rede Densa configurada com perda Binária para duas categorias de peças.	Não aplicou.	Aplicou incorretamente.	Aplicou corretamente.
8	Auditoria Gráfica (Até 1,00 pt): Geração visual correta das curvas de <i>Loss</i> e <i>Acurácia</i> (Treino vs Validação) utilizando Matplotlib ou Seaborn.	Não aplicou.	Aplicou incorretamente.	Aplicou corretamente.